

產品需求預測AI



張祐瑋

NYCU
教育所

Team leader
XGB coder



吳書華

NCCU
通訊所


LSTM coder
Chart analyst



邱柏軒

THU
資訊工程系

LSTM coder



陳晁遠

CGU
工業設計系

Infor collector
Briefing maker

目錄

背景	4
現況	8
問題	11
解決方案	13
改善後變化	56
預計效益	58
未來展望	60

傳產 製造業 供應商..

倉儲

排程

原料

下季度產品需求

Ex:NVIDIA營收



資料來源(<https://statementdog.com/analysis/NVDA/income-statement>)

AS IS

供應問題

訂價問題


預測下季產品需求 提早擬定佈局

問題

該如何建構AI 預測下季產品需求

解決方案

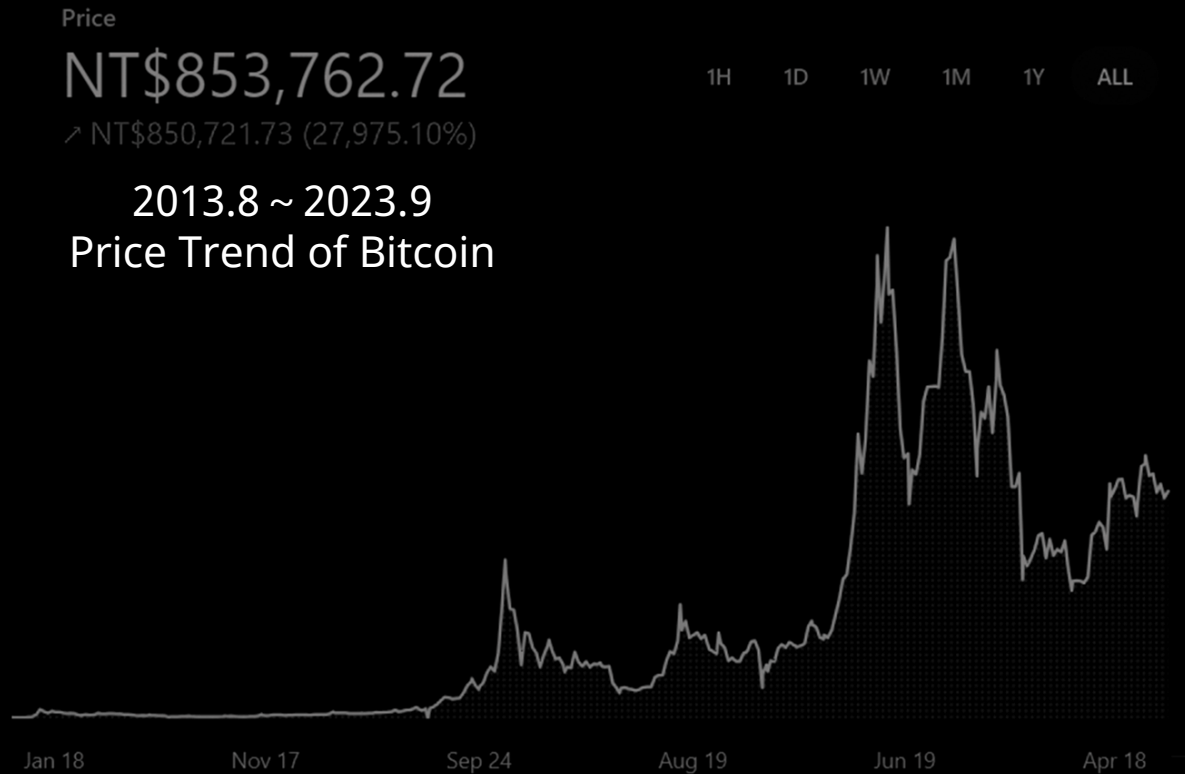
模塊化AI模型



影響因素小x

1. 新遊戲和軟體發布
2. 礦業需求(ex:加密貨幣)
3. 新技術的釋出
4. 全球供應鏈
5. 市場競爭

廠商數據示意圖



資料來源(<https://www.coinbase.com/price/bitcoin>)

Bitcoin skeleton

日期	收市	開市
2023/9/25	26,207.30	26,251.60
2023/9/24	26,251.50	26,579.00
2023/9/23	26,579.20	26,581.70
2023/9/22	26,581.90	26,569.50
2023/9/21	26,570.00	27,125.20
2010/7/22	0.1	0.1
2010/7/21	0.1	0.1
2010/7/20	0.1	0.1
2010/7/19	0.1	0.1
2010/7/18	0.1	0


資料來源(<https://hk.investing.com/crypto/bitcoin/historical-data>)

廠商數據示意圖

年份	顯卡系列	初始價格
2000年	GeForce2	約199美金
2004年	GeForce6	約199 ~ 399美金
2006年	GeForce8	約199 ~ 599美金
2008年	GeForce9	約199 ~ 399美金
2010年	GeForce400	約199 ~ 499美金
2012年	GeForce600	約199 ~ 499美金
2014年	GeForce700	約199 ~ 699美金
2016年	GeForce10	約199 ~ 699美金
2018年	GeForce20	約349 ~ 1199美金

資料來源
(chatgpt)

Number of AI Publications in the World, 2010–21
Source: Center for Security and Emerging Technology, 2022 | Chart: 2023 AI Index Report



資料來源(Artificial Intelligence Index Report 2023-Stanford University
chrome-
extension://efaidnbmnnnibpcajpcglclefindmkaj/https://aiindex.stanford.edu/wp-content/uploads/2023/04/HAI_AI-Index-Report_2023.pdf)

廠商數據示意表

X				y
時間	比特幣價格	AI、影視	性價比	需求量
2021/1/1	10201	0.323	0.323	1111
2021/1/2	2221	0.843	0.121	225
.....				
.....				
.....				
2023/9/29	331	75.292	0.732	2348
2023/9/30	2441	83.391	0.422	18226

滾動預測示意表

時間	1	2	3	4
比特幣價格	10201	2221	331	2441
AI、影視	0.323	0.843	75.292	83.391
性價比	0.323	0.121	0.732	0.422
需求量	1111	225	2348	18226
時間	2	3	4	5
比特幣價格	2221	331	2441	2213
AI、影視	0.843	75.292	83.391	9.311
性價比	0.121	0.732	0.422	0.312
需求量	225	2348	18226	17002

.....

.....

預測目標小y

未來需求量


如何建構AI

模型搭建驗證-以Kaggle為例

Forecasts for Product Demand

Make Accurate Forecasts for Thousands of Different Products

[Data Card](#) [Code \(25\)](#) [Discussion \(1\)](#)



About Dataset

Context

The dataset contains historical product demand for a manufacturing company with footprints globally. The company provides thousands of products within dozens of product categories. There are four central warehouses to ship products within the region it is responsible for. Since the products are manufactured in different locations all over the world, it normally takes more than one month to ship products via ocean to different central warehouses. If forecasts for each product in different central with reasonable accuracy for the monthly demand for month after next can be achieved, it would be beneficial to the company in multiple ways.

Content

Historical Product Demand.csv - CSV data file containing product demand for encoded product id's

Usability ⓘ

8.82

License

[GPL 2](#)

Expected update frequency

Not specified

Tags

[Business](#) [Investing](#)

資料來源

(<https://www.kaggle.com/datasets/felixzhao/productdemandforecasting>)

RAW DATA

TOTAL:1048576

DATE:2011-2017

```
# check the null data
data.isna().sum()
```

```
Product_Code      0
Warehouse         0
Product_Category  0
Date              11239
Order_Demand      0
dtype: int64
```


A	B	C	D	E
Product_Code	Warehouse	Product_Categ	Date	Order_Demand
Product_0588	Whse_S	Category_032	2012/1/2	54
Product_2001	Whse_S	Category_005	2012/1/2	500
Product_2004	Whse_S	Category_005	2012/1/2	1000
Product_1391	Whse_S	Category_019	2012/1/2	200
Product_1355	Whse_S	Category_019	2012/1/2	5000
Product_1281	Whse_S	Category_019	2012/1/2	14000
Product_1502	Whse_S	Category_019	2012/1/2	31250
Product_1823	Whse_C	Category_006	2012/1/3	15000
Product_1823	Whse_C	Category_006	2012/1/3	20000
Product_1016	Whse_S	Category_007	2012/1/3	300
Product_0033	Whse_C	Category_005	2012/1/3	1000
Product_1092	Whse_S	Category_024	2012/1/3	1
Product_1570	Whse_S	Category_019	2012/1/3	90000
Product_1571	Whse_S	Category_019	2012/1/3	18000
Product_1431	Whse_S	Category_019	2012/1/3	100000
Product_1264	Whse_S	Category_019	2012/1/3	20000
Product_2139	Whse_S	Category_009	2012/1/3	200
Product_1350	Whse_C	Category_019	2012/1/3	10000

DELETE 2011&2017



SUM DATA

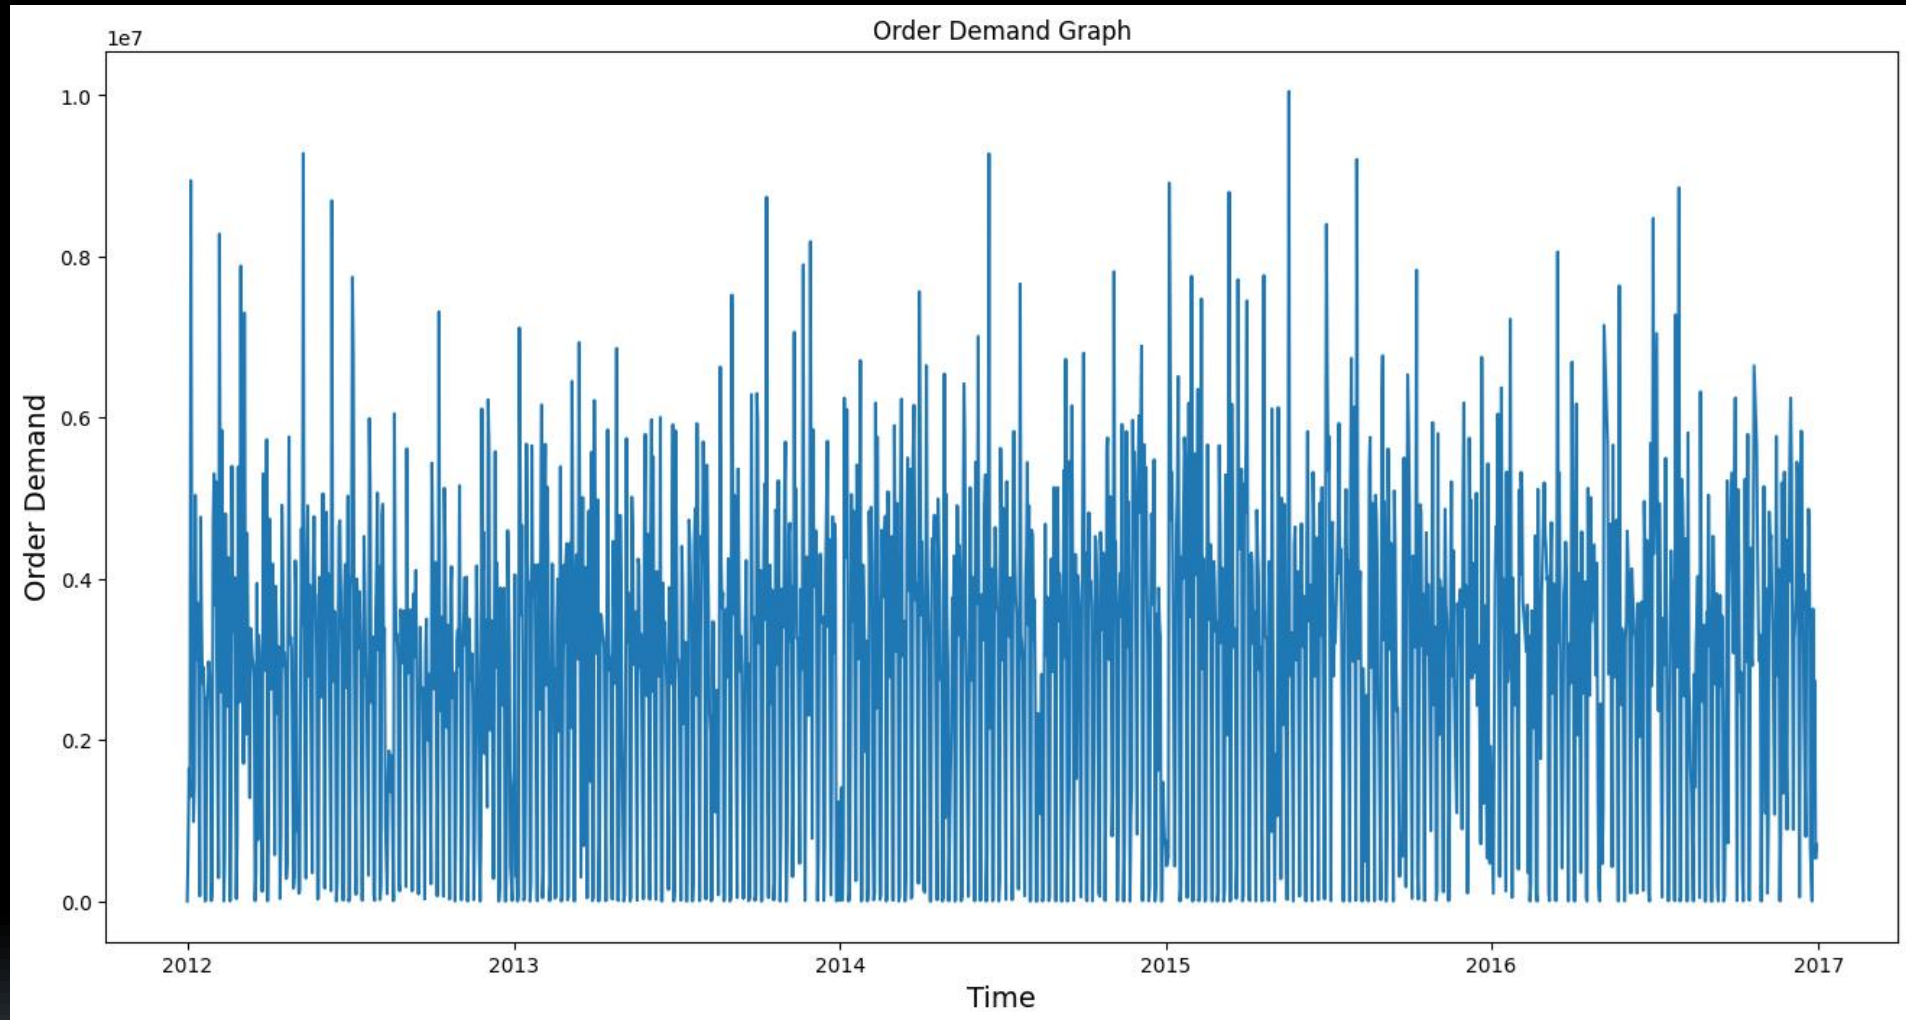
A	B	C	D	E
Product_Code	Warehouse	Product_Categ	Date	Order_Demand
Product_0588	Whse_S	Category_032	2012/1/2	54
Product_2001	Whse_S	Category_005	2012/1/2	500
Product_2004	Whse_S	Category_005	2012/1/2	1000
Product_1391	Whse_S	Category_019	2012/1/2	200
Product_1355	Whse_S	Category_019	2012/1/2	5000
Product_1281	Whse_S	Category_019	2012/1/2	14000
Product_1502	Whse_S	Category_019	2012/1/2	31250
Product_1823	Whse_C	Category_006	2012/1/3	15000
Product_1823	Whse_C	Category_006	2012/1/3	20000
Product_1016	Whse_S	Category_007	2012/1/3	300
Product_0033	Whse_C	Category_005	2012/1/3	1000
Product_1092	Whse_S	Category_024	2012/1/3	1
Product_1570	Whse_S	Category_019	2012/1/3	90000
Product_1571	Whse_S	Category_019	2012/1/3	18000
Product_1431	Whse_S	Category_019	2012/1/3	100000
Product_1264	Whse_S	Category_019	2012/1/3	20000
Product_2139	Whse_S	Category_009	2012/1/3	200
Product_1350	Whse_C	Category_019	2012/1/3	10000



1048576 ⇒ 1681

A	B
Date	Order_Demand
2012/1/1	2
2012/1/2	680277
2012/1/3	1645257
2012/1/4	1295861
2012/1/5	8941774
2012/1/6	4390735
2012/1/8	987149
2012/1/9	1442691
2012/1/10	5038288
2012/1/11	3321775
2012/1/12	2997768
2012/1/13	3699049
2012/1/15	64250
2012/1/16	4766348
2012/1/17	3463741
2012/1/18	2711838
2012/1/19	2904422
2012/1/20	2563689

DO NOT REMOVE OUTLIER



兩種AI模型比較

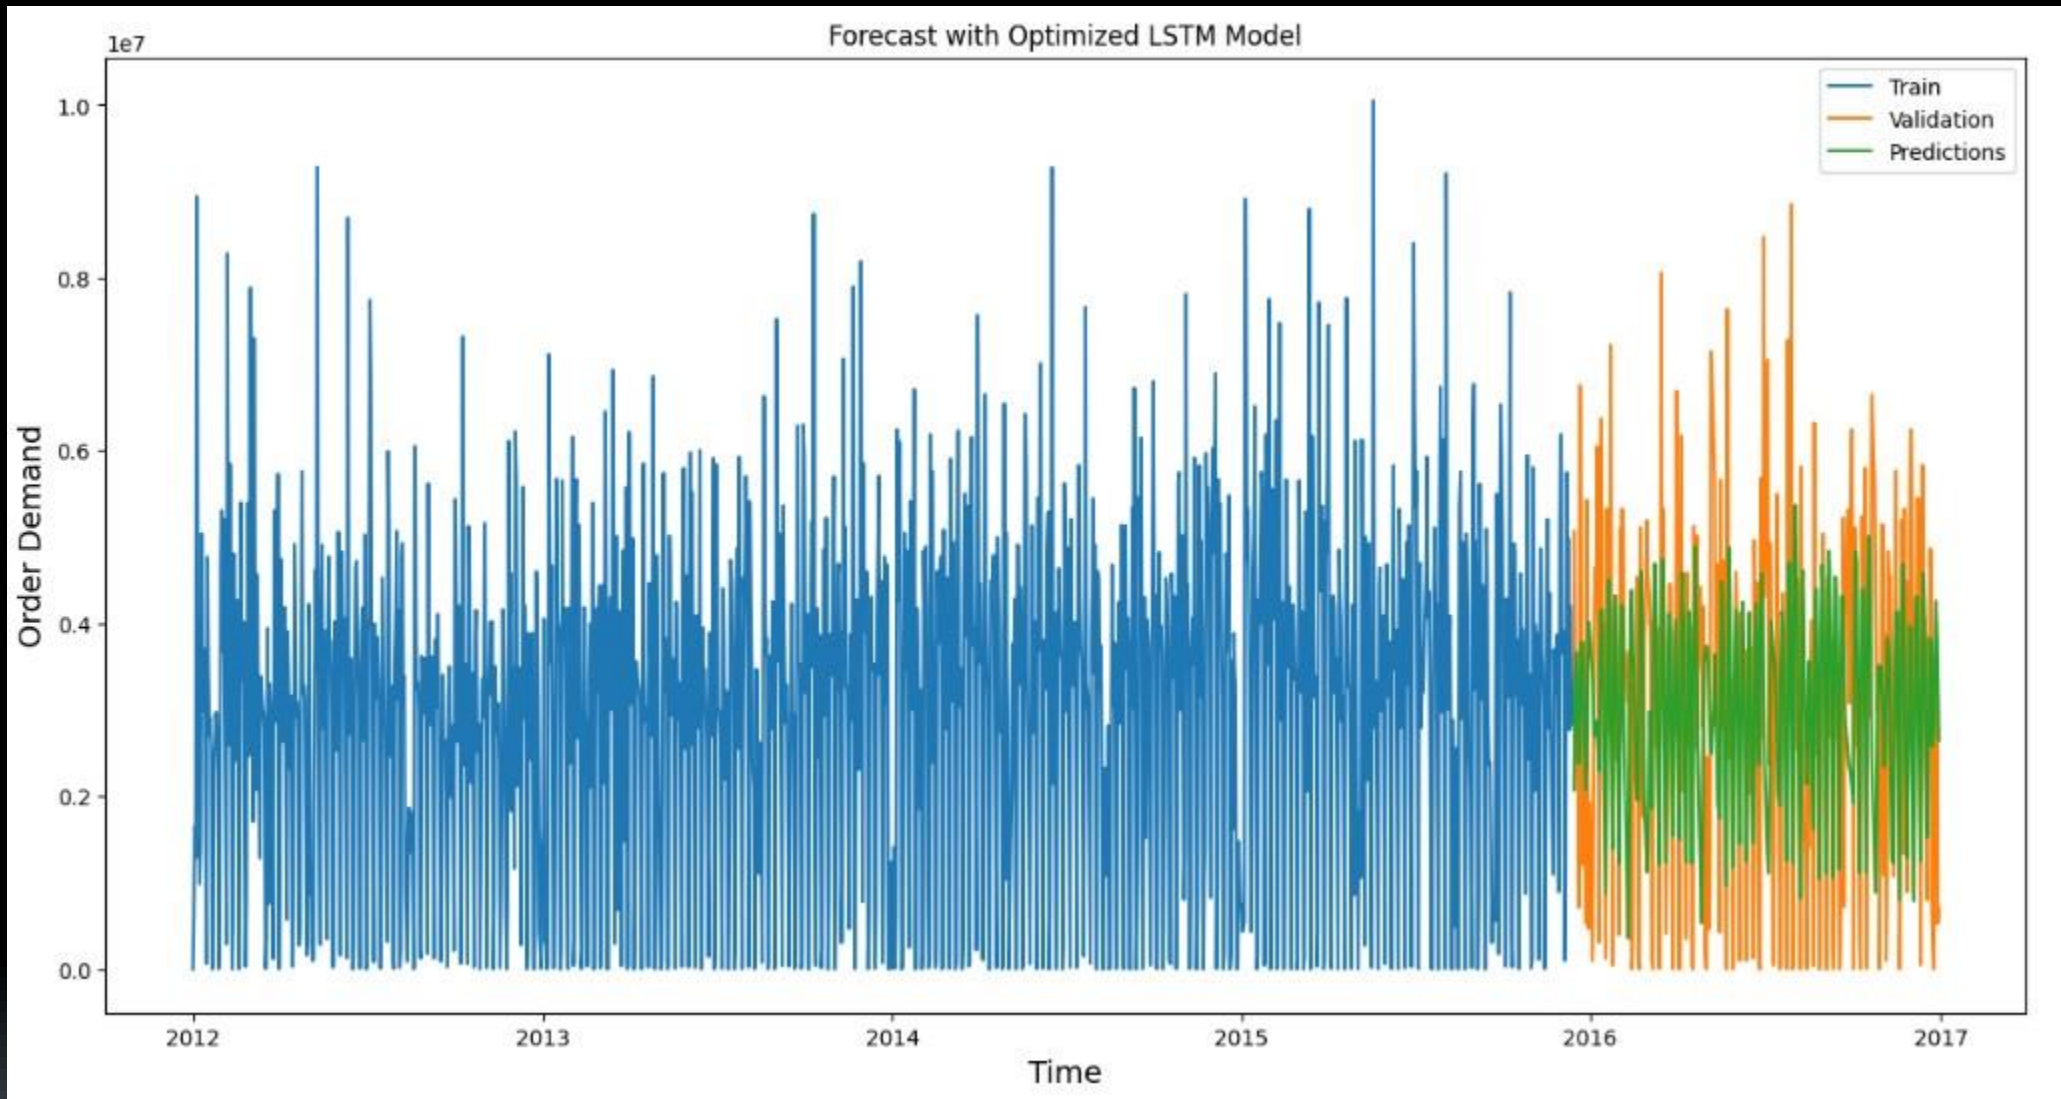
LSTM

XGB

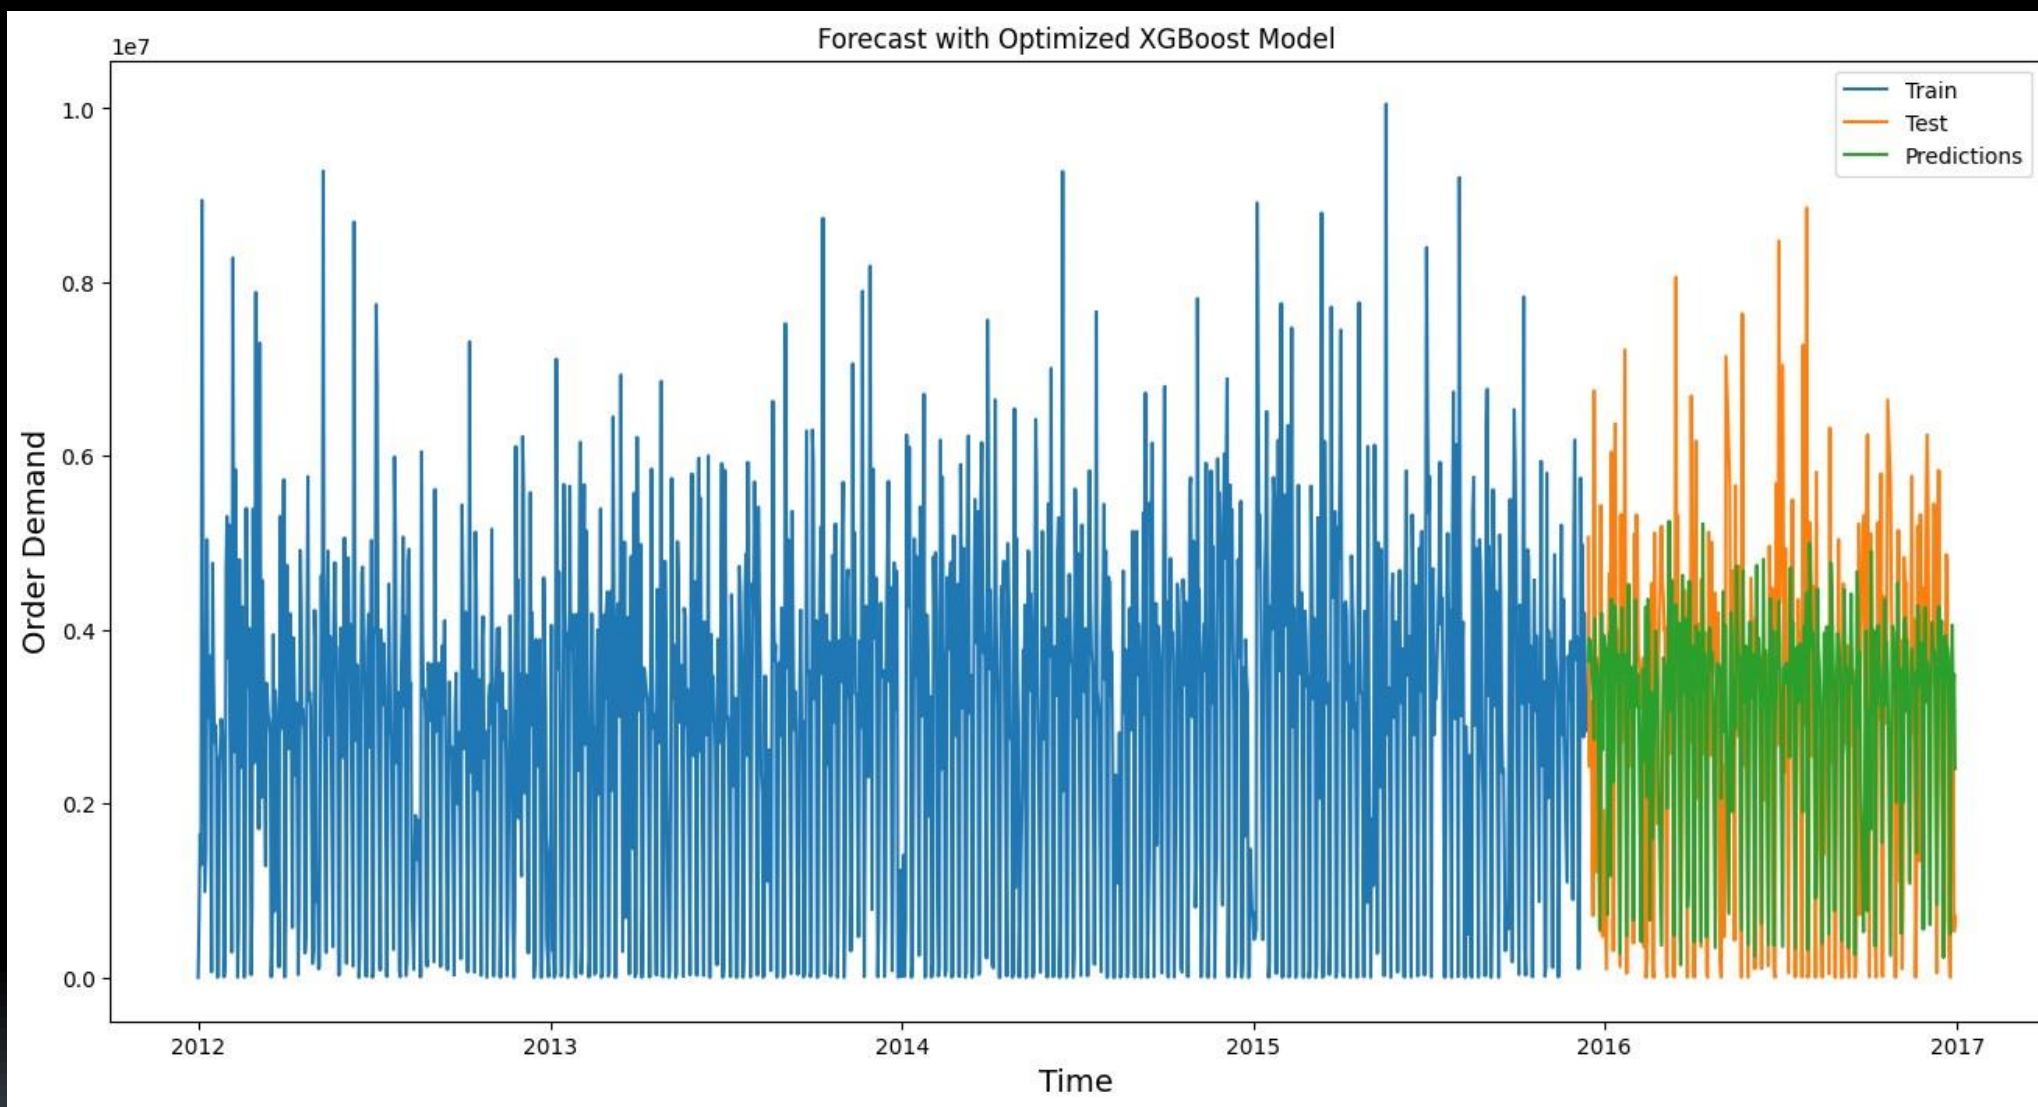
LSTM & XGB

特點	LSTM	XGBoost
模型類型	循環神經網絡 (RNN)	梯度提升樹 (Gradient Boosting Tree)
應用領域	序列數據，自然語言處理，時間序列預測	監督式學習，分類，回歸，排名等
長期依賴性處理	擅長處理長期依賴性，適合序列數據	較少擅長處理長期依賴性
超參數調整	複雜，需要調整多個超參數	相對簡單，少量超參數
適用數據大小	適用於大型數據集，需要大量數據訓練	適用於中小型數據集
預測性能	在某些序列數據任務上表現優秀	在結構化數據的分類和回歸任務上表現優秀
訓練時間	較長，需要更多的訓練時間	較短，訓練速度較快

LSTM



XGB



優化方向

調整窗口

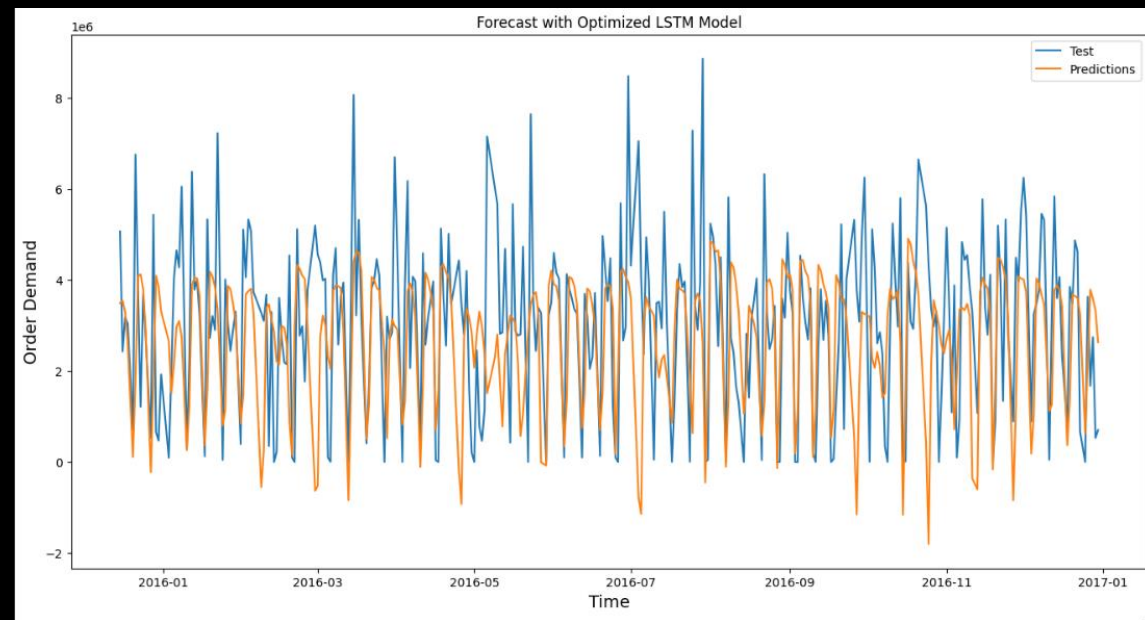

調整參數



LSTM

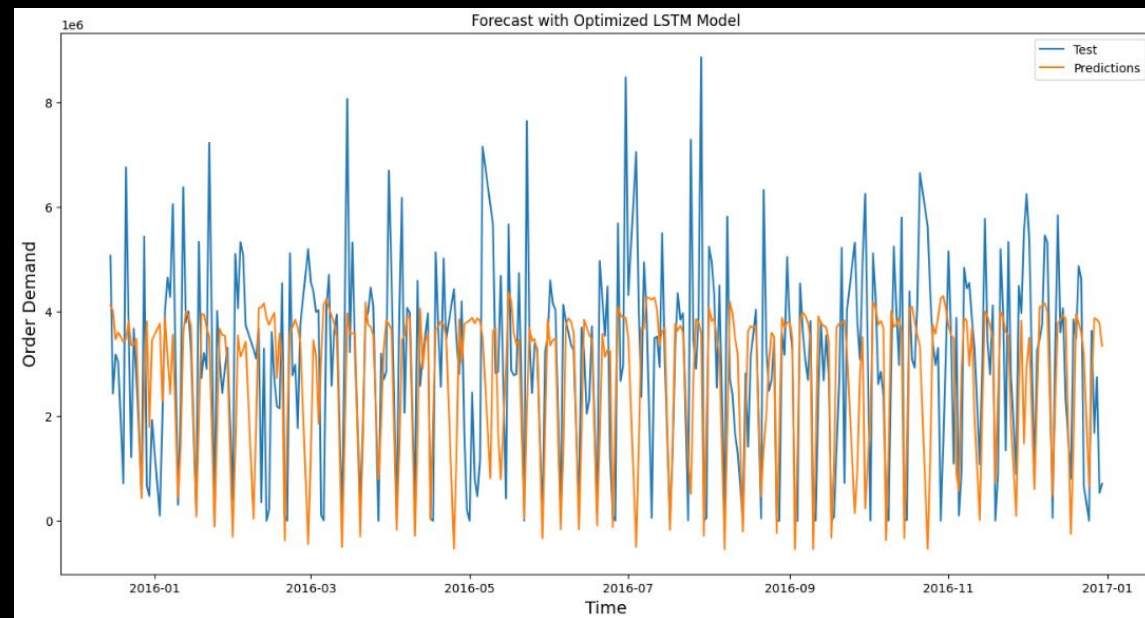

固定神經層 調整Window大小

結果

Window	MAE	MSE
7	0.1387	0.0363
14	0.1483	0.0360
30	0.1482	0.0361
60	0.1567	0.0376
90	0.1504	0.0405







窗口 90 不準且極端值多

窗口 7 較準但極端值多

窗口 30 極端值少且有誤差收斂之趨勢

LSTM


固定Window大小 調整神經層數

結果

LSTM層數	MAE	MSE
7	0.158	0.037
5	0.152	0.037
3	0.161	0.038
2	0.163	0.039


過程

7




過程

5




過程

3



過程

2



層數 多 預測趨保守
層數 少 預測起伏大

5層結果較能準確且穩定的預測

XGB

調整Window大小

Random grid search 取最佳參數

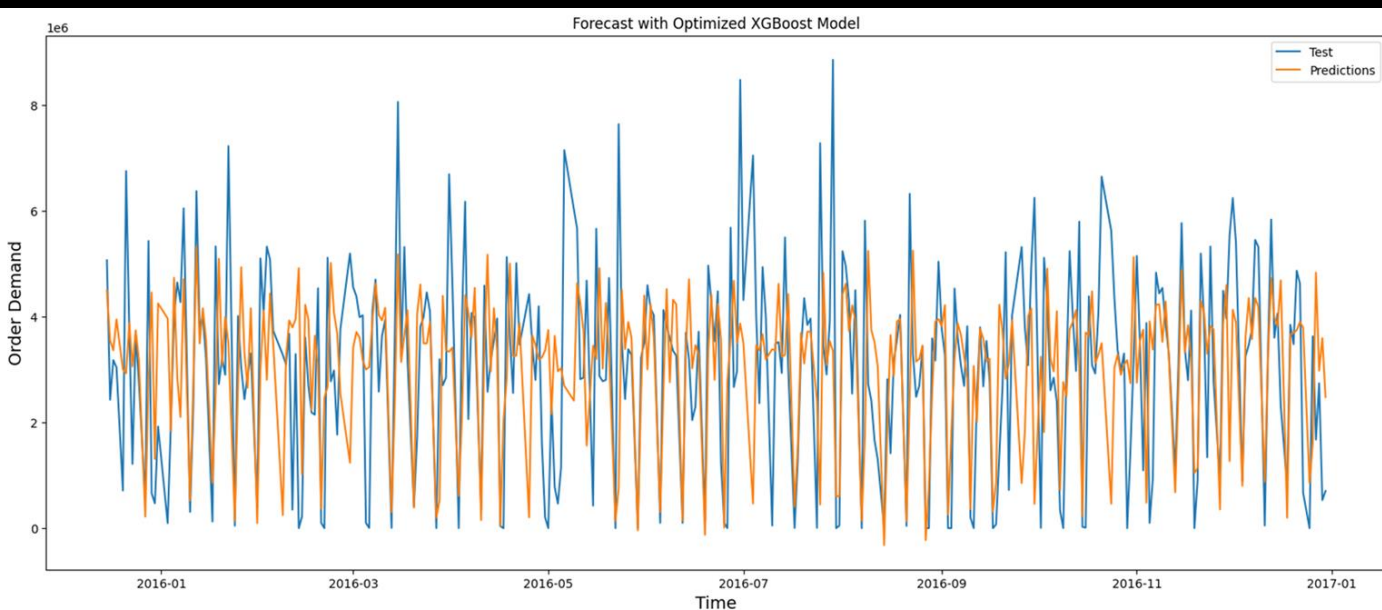
結果

XGBoost	MAE	MSE
7	0.135	0.033
14	0.135	0.032
30	0.137	0.033
60	0.135	0.032
90	0.136	0.032


模型比較

	MAE	MSE	應用
XGBoost (window=14)	0.135	0.032	較準確預測
LSTM (window=30 層數=5)	0.152	0.037	較穩定預測

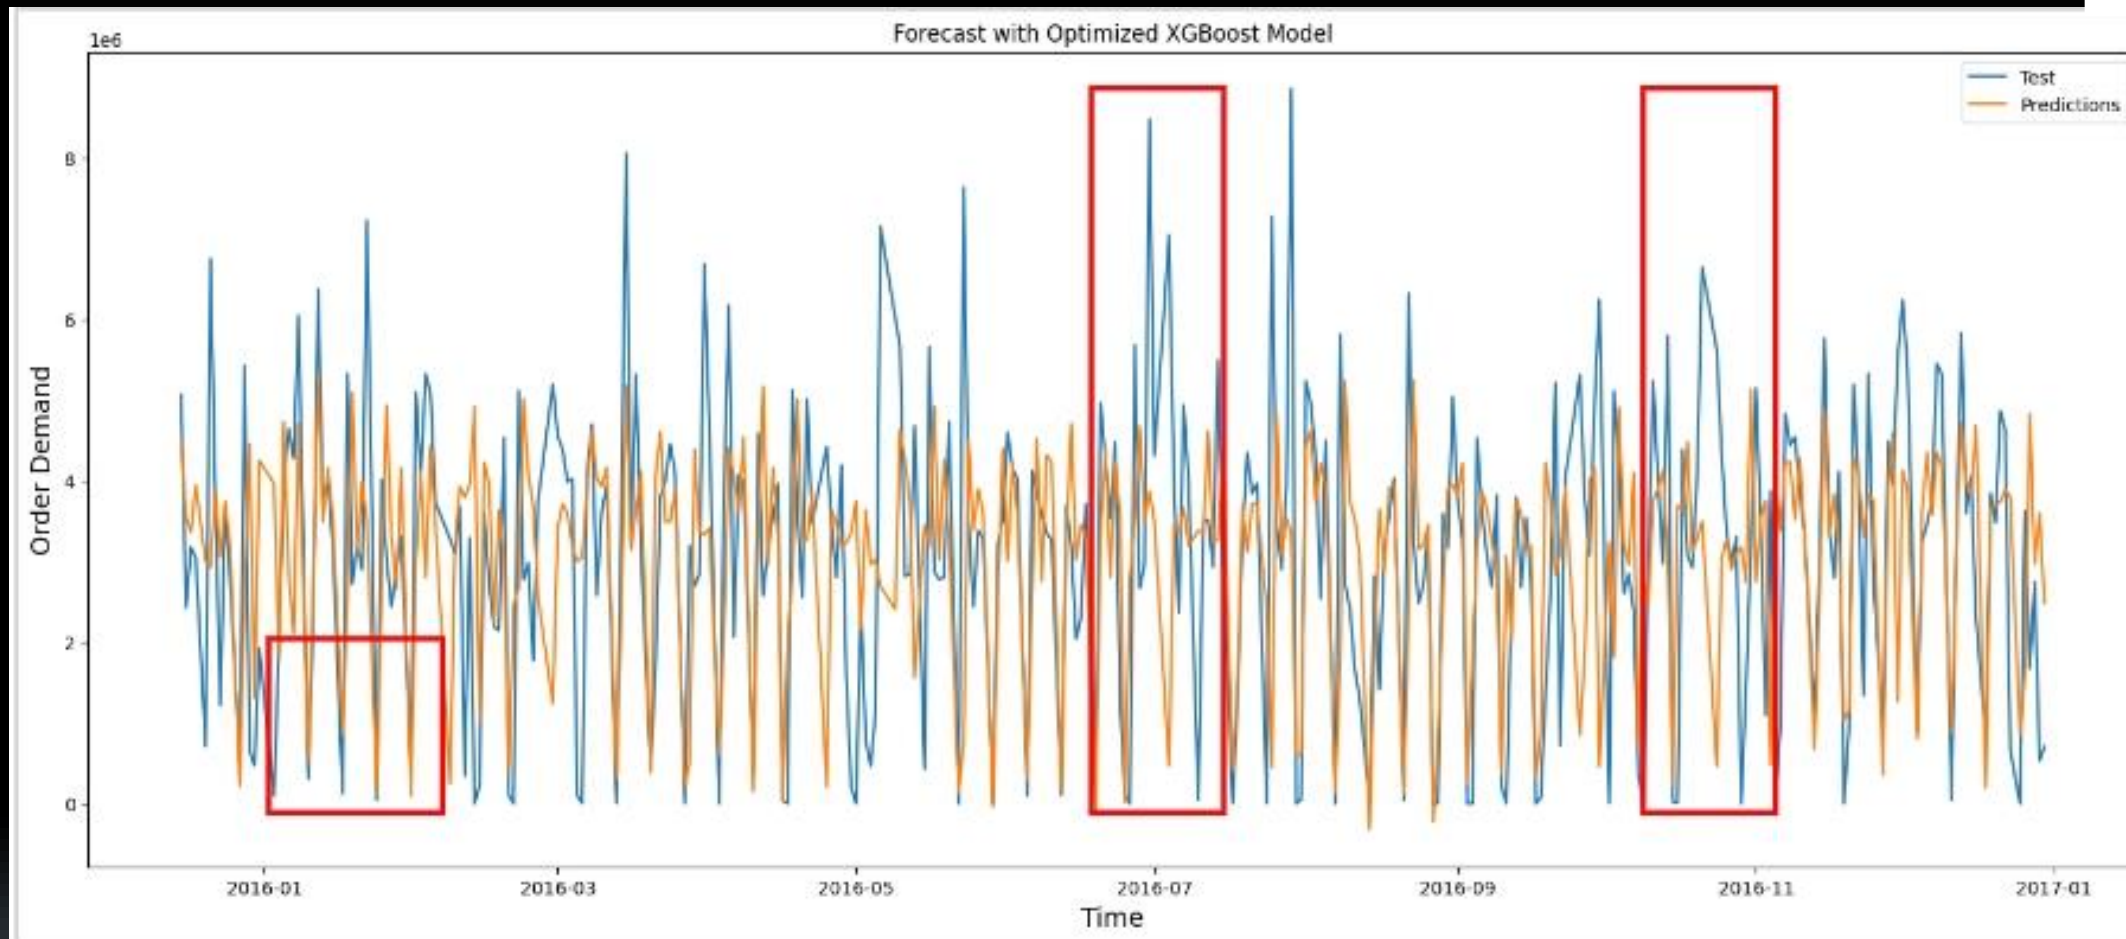
過程



← XGBoost



LSTM →

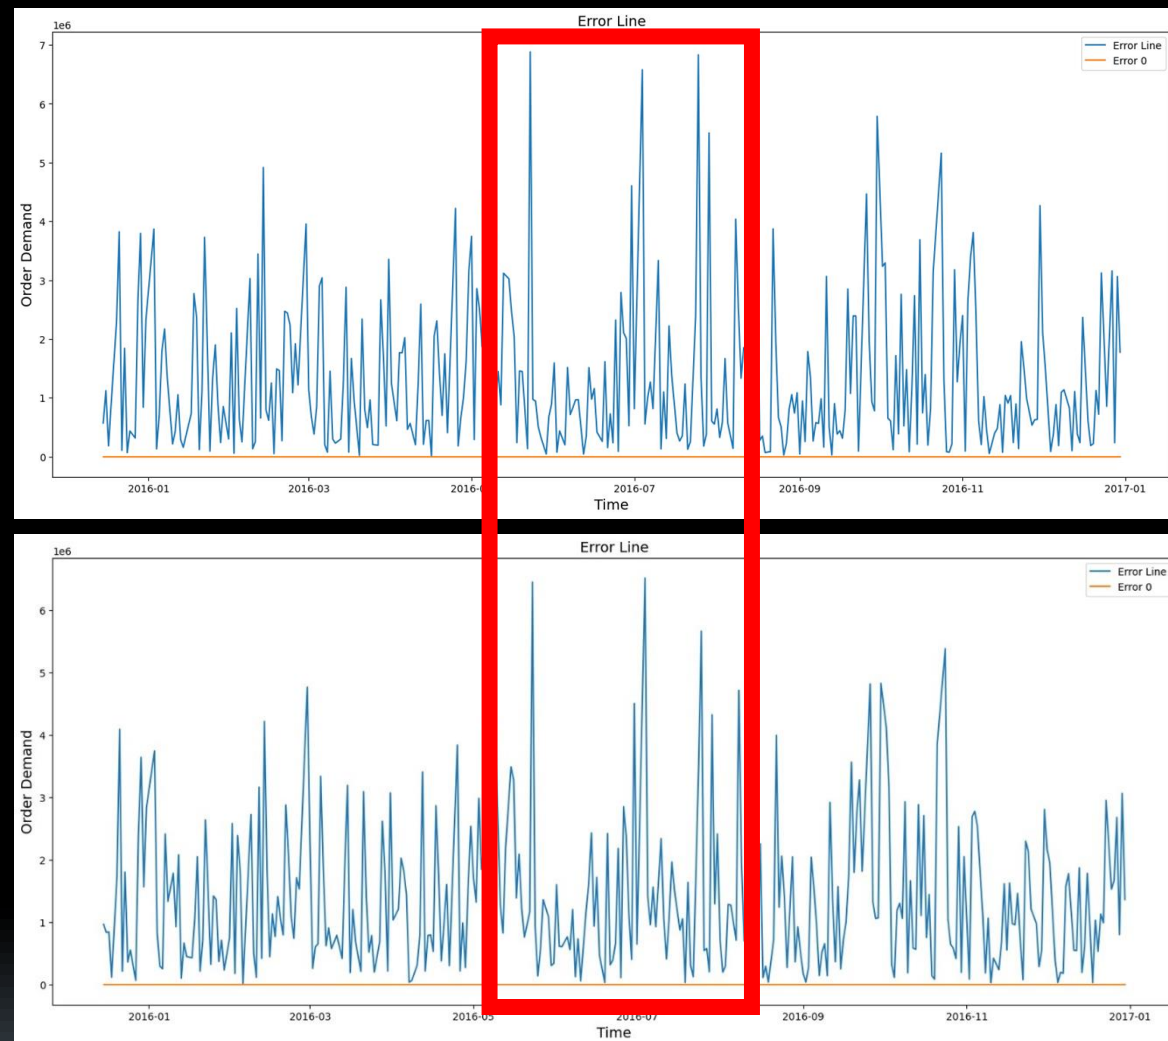


方案31/36

誤差値

Window=14

Window=60



Detail analysis

6月中


Order_Demand	Predictions	Date
2301636	3633022.5	2016-06-16
3714665	2548628.2	2016-06-17
132705	203888.22	2016-06-19
4963105	2983619.8	2016-06-20
4259115	4471849.5	2016-06-21
3533007	2942901.5	2016-06-22
4476939	3786880.8	2016-06-23
1231446	3385439.2	2016-06-24
100000	788307	2016-06-25

7月初


8474968	3840459.5	2016-06-30
4311442	3285460	2016-07-01
7044944	698810.6	2016-07-04
4012352	3012213	2016-07-05
2362337	2848164.5	2016-07-06
4935639	3255365.8	2016-07-07
4007045	3411961.8	2016-07-08
50030	4001280	2016-07-10

月趨勢比較

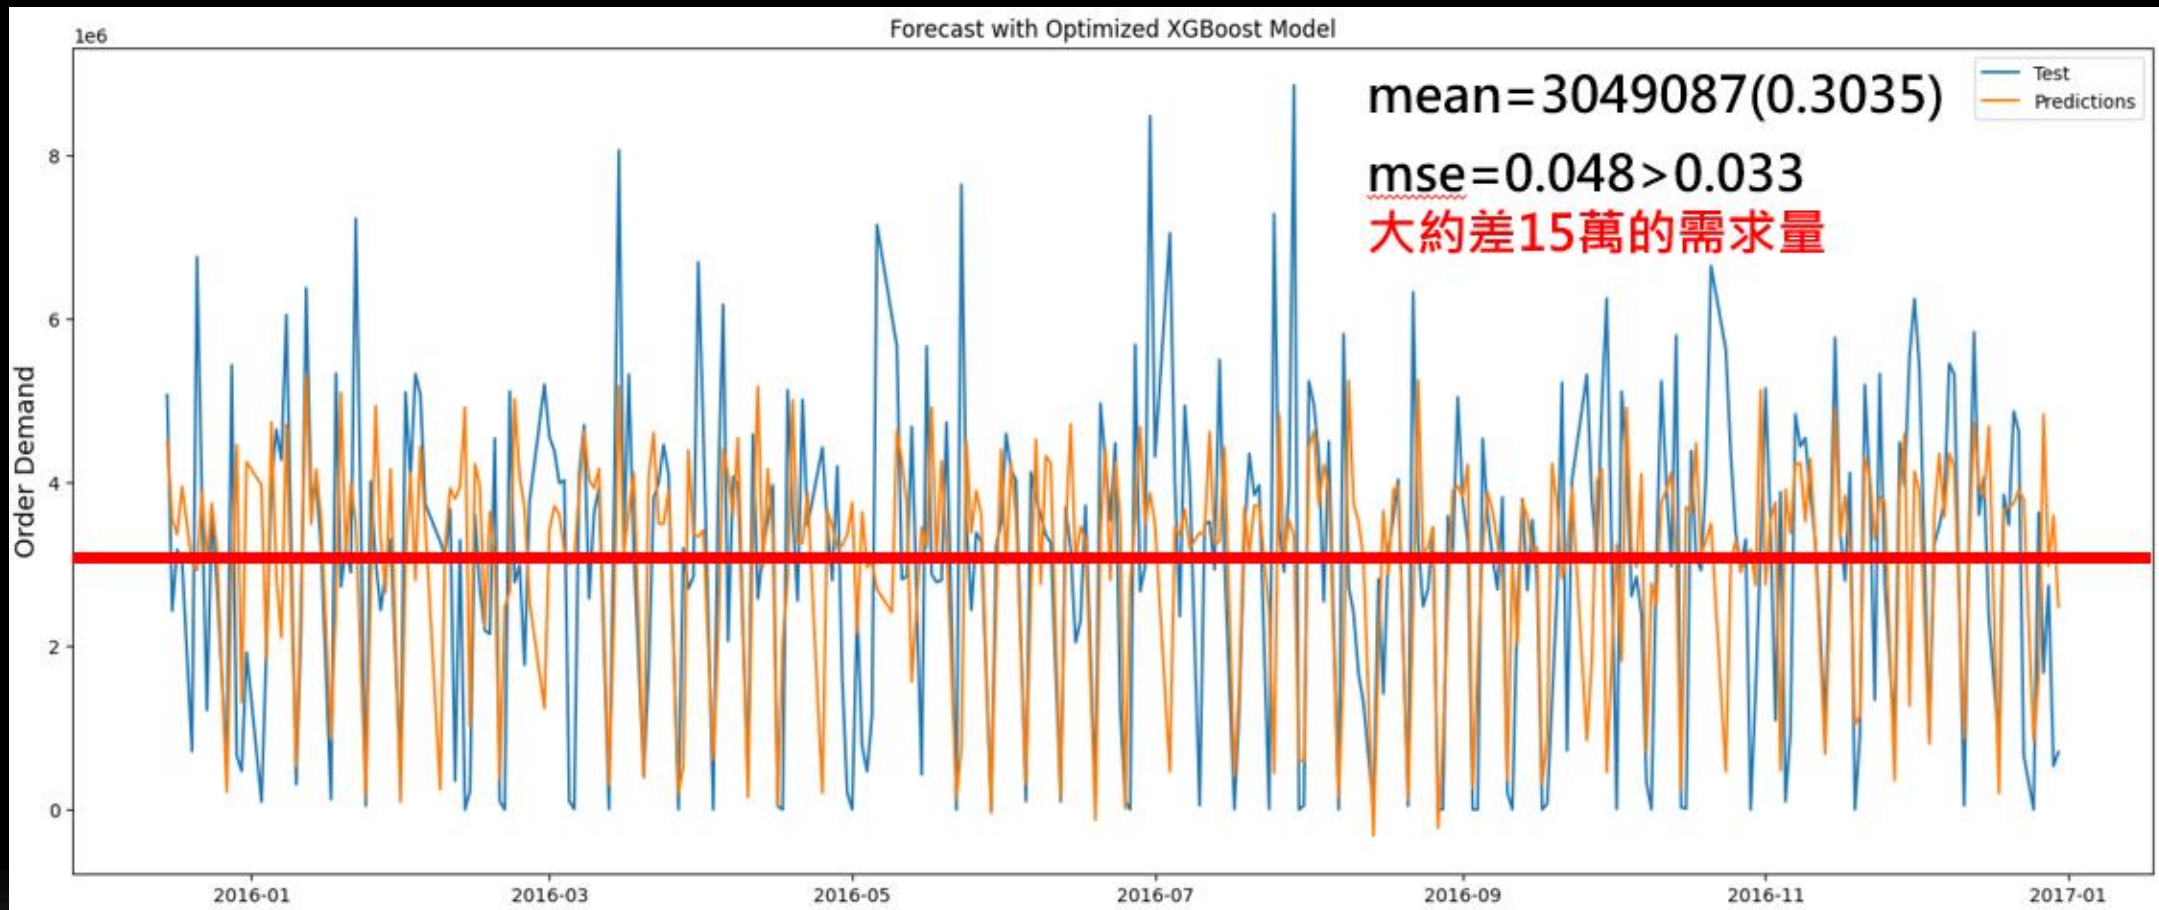
月需求量結果



預測/實際



AI > 人工預測



模擬驗證結論

- 1.資料時間連續性
- 2.資料總數增加
- 3.加入影響因素(小x)

實際系統架構

輔導廠商收
集數據

訓練AI

預測結果

模型優化

改善後變化

及早排程調整

原料調配優化

預計效益

減少無謂成本

擬定更優售價

提升製造持續性

未來展望

拓展通用性
精確預測值

Thanks for Listening

Q&A